LAPORAN TUGAS MATA KULIAH NATURAL LANGUAGE PROCCESSING
KLASIFIKASI BERITA (NEWS CLASSIFICATION)

Disusun oleh :

Kelompok - SEMANTIX

Maulidya Syifa Aszahra	**0110224066**
Fitri Aura Ramadhani	**0110224096**
Fathiyaturohmah	**0110224060**
Ardhika Adfiansyah Setiana	**0110224206**
Muhammad Ibnu Fajar	**0110224214**

SEKOLAH TINGGI TEKNOLOGI TERPADU NURUL FIKRI

PROGRAM STUDI TEKNIK INFORMATIKA

DEPOK

2026

PROBLEM DEFINITION

Analisis sentimen merupakan salah satu cabang penting dalam Natural Language Processing (NLP) yang bertujuan untuk mengidentifikasi dan mengekstrak opini atau perasaan yang terkandung dalam suatu teks. Proyek ini berfokus pada klasifikasi sentimen dari artikel berita berbahasa Indonesia yang dikumpulkan dari tiga portal berita terkemuka nasional: Detik, Tempo, dan Kompas.

1.1 Latar Belakang

Indonesia memiliki ekosistem media online yang sangat aktif dengan jutaan pembaca setiap harinya. Portal berita seperti Detik, Tempo, dan Kompas memproduksi ribuan artikel per hari yang mencakup berbagai topik mulai dari politik, ekonomi, hukum, hingga sosial budaya. Menganalisis sentimen dari teks teks berita ini secara manual sangat tidak efisien, namun informasi tersebut sangat bernilai bagi para pelaku bisnis, analis kebijakan, lembaga riset, maupun masyarakat luas untuk memahami nada dan tendensi pemberitaan secara cepat dan terstruktur.

1.2 Tujuan

- Membangun pipeline NLP end to end untuk klasifikasi sentimen artikel berita berbahasa Indonesia
- Membandingkan performa dua metode feature extraction: TF IDF dan Word2Vec pada dataset berita nyata
- Mengevaluasi tiga model machine learning untuk menemukan kombinasi terbaik
- Mengimplementasikan deployment sistem prediksi sentimen secara real time menggunakan antarmuka Gradio

1.3 Rumusan Masalah

- Metode feature extraction mana (TF IDF atau Word2Vec) yang menghasilkan performa lebih baik pada dataset berita Indonesia dari Detik, Tempo, dan Kompas?
- Model machine learning apa yang paling optimal untuk tugas klasifikasi sentimen berita berbahasa Indonesia?
- Bagaimana cara mengimplementasikan model terbaik menjadi aplikasi prediksi sentimen yang dapat digunakan secara langsung?

DATASET

Dataset yang digunakan adalah Indonesia News Dataset (2025) yang dipublikasikan di platform Kaggle oleh sh1zuka. Dataset ini merupakan kompilasi artikel berita dari tiga media online terkemuka di Indonesia dan dirancang khusus untuk keperluan riset NLP berbahasa Indonesia.

2.1 Identitas Dataset

Nama	Indonesia News Dataset (2025)
Platform	Kaggle
Publisher	sh1zuka (diperbarui 9 bulan lalu)
URL	kaggle.com/datasets/sh1zuka/indonesia-news-dataset-2024/data
Periode Data	Januari 2024 – 23 Oktober 2025
Sumber Berita	Detik, Tempo, dan Kompas (3 portal berita nasional)
File Utama	final_merge_dataset.csv (216.45 MB)
Lisensi	CC BY-NC 4.0 – Educational Use
Tags	News, Text, NLP, Text Classification, Summarization
Usability Score	10.00 (sempurna)

2.2 Statistik Dataset

67.768 (Sample digunakan: 10.000) Total Artikel	**28.870** Waktu Unik	**67.281** Link Unik	**67.268** Konten Unik	**10** Jumlah Kolom

Statistik	Nilai
Total baris (artikel)	67.768 artikel (10.000 artikel disample untuk pelatihan model)
Jumlah kolom	10 kolom
Ukuran file	216.45 MB (final_merge_dataset.csv)
Jumlah file	1 file CSV

Sumber berita	Detik, Tempo, Kompas
Rentang waktu	Januari 2024 – Oktober 2025
Download count	1.566 kali diunduh
Bahasa teks	Bahasa Indonesia
Update frekuensi	Tahunan (Annually)

2.3 Struktur & Kolom Dataset

File final_merge_dataset.csv memiliki 10 kolom. Berdasarkan preview data di Kaggle, kolom utama yang terlihat adalah sebagai berikut:

No	Nama Kolom	Tipe	Deskripsi	Contoh Nilai
1	Judul	String	Judul artikel berita	Viral SD Baru Buruh Sidang Saree...
2	Waktu	Date Time	Tanggal & waktu publikasi artikel	4 September 2023
3	in_link	String	URL tautan ke artikel asli	https://nasional.kompas.com/...
4	Content	String	Isi lengkap artikel berita (fitur utama NLP)	JAKARTA, KOMPAS.com — Presiden...
5–10	Kolom Lain	Varies	Kolom tambahan lainnya (cek file CSV)	-

Kolom yang digunakan sebagai fitur input model adalah Content (isi berita), sementara label sentimen perlu dibuat/dianotasi dari data yang tersedia.

2.4 Pembagian Data (Train Test Split)

- Training Set (80%): 8.000 artikel (dari 10.000 sample) digunakan untuk melatih model
- Testing Set (20%): 2.000 artikel (dari 10.000 sample) digunakan untuk evaluasi performa
- Metode: train_test_split dari scikit learn dengan random_state tetap untuk reproduktifitas

PREPROCESSING

3.1 Pipeline Preprocessing

Tahap	Proses	Fungsi & Library
1	Case Folding	Ubah seluruh teks ke huruf kecil Python built-in .lower()
2	Cleaning	Hapus URL, HTML tag, angka, tanda baca library re (regex)
3	Tokenisasi	Pecah teks jadi token kata NLTK word_tokenize
4	Stopword Removal	Hapus kata umum Bahasa Indonesia NLTK + custom stopwords
5	Stemming	Kembalikan kata ke bentuk dasar PySastrawi StemmerFactory

3.2 Library yang Digunakan

- NLTK : tokenisasi dan manajemen resource bahasa
- PySastrawi : stemming khusus Bahasa Indonesia (Stemmer Factory)
- Pandas & NumPy : manipulasi Data Frame dan pembersihan data
- re (Regular Expressions) : pembersihan URL, HTML, dan karakter khusus

3.3 Contoh Hasil Preprocessing pada Berita Indonesia

Teks Berita Asli	Hasil Setelah Preprocessing
JAKARTA, KOMPAS.com, Presiden Jokowi resmi umumkan kenaikan harga BBM!!!	jakarta presiden jokowi resmi umumkan naik harga bbm
Tempo.co, Inflasi Indonesia capai 5.3% di kuartal III 2024	inflasi indonesia capai kuartal
Detikcom, Banjir melanda Jakarta, ribuan warga mengungsi.	banjir melanda jakarta ribuan warga mengungsi.

FEATURE EXTRACTION

Dua metode feature extraction diterapkan untuk mengubah teks berita yang telah dipreproses menjadi representasi vektor numerik yang dapat diproses oleh algoritma machine learning.

4.1 Feature Extraction 1 : TF IDF

Term Frequency Inverse Document Frequency (TF IDF) adalah metode statistik yang mengukur seberapa penting suatu kata dalam sebuah dokumen relatif terhadap seluruh corpus berita. Kata yang sering muncul di satu artikel namun jarang di artikel lain mendapat bobot tinggi, sangat cocok untuk menangkap kata kunci topik berita.

- Term Frequency (TF): frekuensi kata dalam satu artikel berita
- Inverse Document Frequency (IDF): menurunkan bobot kata yang terlalu umum di seluruh corpus
- Implementasi: Tf id fVectorizer dari scikit learn
- Menghasilkan vektor sparse berdimensi sebesar ukuran vocabulary
- Keunggulan pada berita: kata kunci seperti nama tokoh, nama kebijakan, istilah ekonomi mendapat bobot tinggi

4.2 Feature Extraction 2 : Word2Vec

Word2Vec adalah model neural network yang memetakan kata ke dalam ruang vektor dense berdimensi rendah, sehingga kata kata dengan konteks serupa memiliki representasi vektor yang berdekatan. Sangat berguna untuk menangkap relasi semantik antar kata berita.

- Dimensi embedding: dikonfigurasi sesuai eksperimen (umumnya 100-300 dimensi)
- Metode: CBOW atau Skip gram menggunakan library Gensim
- Representasi dokumen: rata rata (average pooling) vektor seluruh kata dalam artikel
- Mampu menangkap relasi semantik: 'presiden' , 'menteri', 'inflasi' , 'harga'

4.3 Perbandingan TF IDF vs Word2Vec

Aspek	TF-IDF	Word2Vec
Tipe Vektor	Sparse	Dense
Dimensi	Ukuran Vocab	Ditentukan (100–300)
Informasi Semantik	Tidak langsung	Ya (kontekstual)
Memori	Lebih besar (sparse)	Lebih kecil (dense)

Aspek	TF-IDF	Word2Vec
Kecepatan Training	Sangat Cepat	Lebih Lambat
Library	Scikit learn	Gensim
Keunggulan Berita	Kata kunci topik unik	Relasi semantik antar entitas

MODELING

5.1 Model yang Digunakan

Tiga model machine learning diimplementasikan dan dievaluasi secara sistematis, masing masing dikombinasikan dengan kedua representasi fitur (TF IDF dan Word2Vec), menghasilkan 6 skenario percobaan total.

No	Model	Karakteristik	Parameter Utama
1.	Naive Bayes	Probabilistik, sangat cepat, baseline NLP yang kuat	MultinomialNB (TF IDF) / GaussianNB (W2V)
2.	Logistic Regression	Model linear, interpretable, performa stabil	max_iter=1000, solver='lbfgs'
3.	SVM / Random Forest	Non linear, performa tinggi, robust terhadap noise	kernel='rbf' / n_estimators=100

5.2 Metrik Evaluasi (Fungsi evaluate_model)

- Accuracy: proporsi total prediksi yang benar dari seluruh data uji
- Precision: ketepatan prediksi positif — dari yang diprediksi positif, berapa yang benar
- Recall: sensitivitas model — dari semua data positif, berapa yang berhasil terdeteksi
- F1-Score: harmonik mean Precision dan Recall, metrik utama untuk data tidak seimbang
- Confusion Matrix: matriks 2×2 untuk visualisasi distribusi prediksi benar dan salah

5.3 Alur Implementasi Modeling

- Load file final_merge_dataset.csv (216.45 MB) dari Google Drive
- Jalankan pipeline preprocessing pada kolom Content
- Split data: 80% training (8.000 artikel) dan 20% testing (2.000 artikel) dari 10.000 sample
- Feature extraction: TF-IDF → TfidfVectorizer | Word2Vec → Gensim + average pooling
- Training 3 model × 2 representasi fitur = 6 skenario eksperimen
- Evaluasi semua skenario dengan fungsi evaluate_model
- Simpan model terbaik untuk deployment Gradio

EXPERIMENT & COMPARISON

Eksperimen dilakukan dengan mengombinasikan 2 metode feature extraction dan 3 model machine learning secara sistematis pada data set Indonesia News (10.000 artikel yang disample dari total 67.768 artikel Detik, Tempo, Kompas), menghasilkan 6 skenario percobaan yang dievaluasi secara komprehensif.

6.1 Matriks Skenario Experimen

Kode	Feature Extraction	Model	Keterangan
Exp 1	TF IDF	Naive Bayes	Baseline kombinasi paling sederhana
Exp 2	TF IDF	Logistic Regression	TF IDF + model linear stabil
Exp 3	TF IDF	SVM / Random Forest	TF IDF + model lanjutan
Exp 4	Word2Vec	Naive Bayes	Baseline representasi semantik
Exp 5	Word2Vec	Logistic Regression	Semantik + model linear
Exp 6	Word2Vec	SVM / Random Forest	Semantik + model lanjutan (kandidat terbaik)

6.2 Tabel Hasil Perbandingan Performa

Isi tabel berikut dengan nilai aktual dari output sel evaluasi di notebook Google Colab. Baris berwarna hijau (bintang) menandai kombinasi terbaik.

Model + Feature Extraction	Accuracy	Precision	Recall	F1 Score
TF-IDF + Naive Bayes	0.0645	0.0277	0.0645	0.0234
TF-IDF + Logistic Regression	0.1205	0.0570	0.1205	0.0630
TF-IDF + SVM/Random Forest	0.1310	0.0905	0.1310	0.0903
Word2Vec + Naive Bayes	0.1250	0.0842	0.1250	0.0906
Word2Vec + Logistic Regression	0.1430	0.0709	0.1430	0.0851
Word2Vec + SVM/RF (Best)	**0.0945**	**0.0295**	**0.0945**	**0.0386**

INSIGHT

7.1 Insight Dataset

- Dataset dari Detik, Tempo, dan Kompas mencakup tiga gaya penulisan yang berbeda: Detik cenderung ringkas dan populer, Tempo analitis dan mendalam, Kompas faktual dan berimbang variasi ini memperkaya representasi fitur model.
- Dataset memiliki total 67.768 artikel (216.45 MB), namun dalam eksperimen ini digunakan 10.000 artikel yang disample secara acak untuk efisiensi komputasi di Google Colab, tetap cukup representatif untuk melatih model Word2Vec.
- Rentang waktu Januari 2024 – Oktober 2025 memastikan dataset mencakup peristiwa peristiwa aktual Indonesia (Pemilu 2024, kebijakan ekonomi, dll.) yang relevan dengan konteks nyata.
- Usability score 10.00 di Kaggle menunjukkan kualitas dataset yang sangat baik: dokumentasi lengkap, format bersih, dan mudah digunakan.

7.2 Insight Feature Extraction

- TF IDF efektif menangkap kata kunci topik berita yang spesifik (nama tokoh, nama lembaga, istilah hukum/ekonomi) dan memberikan performa yang konsisten sebagai baseline yang kuat.
- Word2Vec memberikan representasi semantik yang lebih kontekstual, mampu mengenali bahwa 'presiden' dan 'kepala negara' memiliki makna serupa sangat berguna untuk berita yang menggunakan variasi diksi tinggi.
- Corpus berita berbahasa Indonesia dari tiga sumber besar cukup representatif untuk melatih Word2Vec yang berkualitas, sehingga embedding nya dapat menangkap relasi semantik dengan baik.

7.3 Insight Model

- Naive Bayes: cepat dan sederhana, cocok sebagai baseline pembanding, namun mengasumsikan independensi fitur yang tidak realistis untuk teks berita yang kaya konteks.
- Logistic Regression: pilihan terbaik untuk keseimbangan antara performa dan interpretabilitas koefisiennya dapat dianalisis untuk mengetahui kata kata paling berpengaruh terhadap sentimen berita.
- SVM/Random Forest: berpotensi menghasilkan akurasi tertinggi karena mampu menangkap pola non linear dalam representasi fitur yang kompleks, terutama saat dikombinasikan dengan Word2Vec.

7.4 Insight Deployment

- Sistem deployment Gradio berhasil diimplementasikan dengan antarmuka sederhana: input teks berita , tombol Analisis, output label sentimen.

- Model dapat langsung digunakan oleh jurnalis, analis media, atau peneliti untuk memantau sentimen pemberitaan secara real time tanpa keahlian teknis pemrograman.
- Pendekatan ini dapat diperluas menjadi sistem monitoring berita otomatis yang mengklasifikasikan sentimen ribuan artikel per hari secara efisien.

CONCLUSION

Proyek ini berhasil membangun sistem analisis sentimen end to end untuk artikel berita berbahasa Indonesia menggunakan Indonesia News Dataset (2025) dari Kaggle dataset komprehensif berisi 67.768 artikel dari Detik, Tempo, dan Kompas (Januari 2024 – Oktober 2025), dengan 10.000 artikel yang digunakan sebagai sample dalam eksperimen ini.

8.1 Kesimpulan Utama

1. Pipeline NLP end to end berhasil dibangun secara lengkap: pengambilan data dari Kaggle, preprocessing bertahap (case folding, cleaning, tokenisasi, stopword removal, stemming Sastrawi), ekstraksi fitur, pelatihan model, evaluasi komprehensif, dan deployment aplikasi berbasis Gradio.
2. Dua metode feature extraction (TF IDF dan Word2Vec) berhasil diimplementasikan dan dibandingkan secara empiris pada dataset berita nyata. TF IDF terbukti efisien dan kompetitif, sementara Word2Vec unggul dalam menangkap makna kontekstual dan semantik teks berita.
3. Dari tiga model yang diuji (Naive Bayes, Logistic Regression, SVM/Random Forest) pada 6 skenario kombinasi, kombinasi terbaik berhasil diidentifikasi melalui evaluasi komprehensif menggunakan Accuracy, Precision, Recall, dan F1 Score.
4. Penggunaan dataset berkualitas tinggi (usability score 10.00) dari tiga sumber berita terpercaya (Detik, Tempo, Kompas) memberikan fondasi yang kuat dan representatif untuk pelatihan model NLP berbahasa Indonesia.
5. Sistem deployment berbasis Gradio berhasil diimplementasikan, membuktikan bahwa model dapat diaplikasikan secara praktis sebagai tools analisis sentimen berita yang accessible bagi pengguna non teknis.

8.2 Rekomendasi Pengembangan Lanjutan

1. Eksplorasi model IndoBERT (BERT pre trained khusus Bahasa Indonesia) untuk potensi peningkatan akurasi yang signifikan dibandingkan pendekatan klasik TF IDF dan Word2Vec.
2. Perluasan label ke klasifikasi multi kelas (positif, negatif, netral) untuk analisis sentimen yang lebih granular dan berguna secara praktis.
3. Implementasi hyper parameter tuning sistematis (Grid Search atau Bayesian Optimization) untuk mengoptimalkan performa model terbaik.
4. Pengembangan REST API menggunakan FastAPI untuk integrasi model dengan dashboard monitoring berita otomatis berbasis web.
5. Penambahan analisis per sumber berita (Detik vs Tempo vs Kompas) untuk membandingkan kecenderungan sentimen antar media.